

```

# Import ----

library(rvest)
library(httr)
library(data.table)
library(dplyr)
library(purrr)
library(stringr)
library(writexl)
library(xml2)
library(readxl)
library(tidyverse)

# Setup & Configuration ----

lista_url_aree <- c(
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?area=Scuole",
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?area=Studenti",
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?
area=Personale%20Scuola",
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?
area=Sistema%20Nazionale%20di%20Valutazione",
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?
area=Edilizia%20Scolastica",
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?
area=Adozioni%20libri%20di%20testo",
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?
area=Bilancio%20integrato%20delle%20scuole",
  "https://dati.istruzione.it/opendata/opendata/catalogo/elements1/?
area=Dati%20di%20monitoraggio"
)

input_folder <- "data/statistiche_istruzione"
data <- "data"
if (!dir.exists(input_folder)) dir.create(input_folder, recursive = TRUE)

# 1. Scraping ----

walk(lista_url_aree, function(url_area) {
  cat("Analisi area:", url_area, "\n")
  nome_settore <- gsub(".*area=", "", url_area)
  nome_settore <- URLdecode(nome_settore) # Converte %20 in spazi
  nome_settore_pulito <- gsub(" ", "_", nome_settore)
  tryCatch({
    risposta_indice <- GET(url_area, config(ssl_verifypeer = FALSE))
    pagina <- read_html(risposta_indice)
    testi_completi <- pagina %>% html_nodes("p, div, span") %>% html_text()
    date_modifica <- testi_completi[grepl("Modified:", testi_completi)]
    links <- pagina %>% html_nodes("a") %>% html_attr("href")
    link_csv_relativi <- links[grepl("\\.csv$", links)] %>% unique()
    cat("Trovati", length(link_csv_relativi), "file CSV in quest'area.\n")
    for (i in seq_along(link_csv_relativi)) {
      link <- link_csv_relativi[i]
      nome_file_originale <- basename(link)
      nome_file_nuovo <- paste0(nome_settore_pulito, "_", nome_file_originale)
      percorso_salvataggio <- file.path(input_folder, nome_file_nuovo)
      url_completo <-
paste0("https://dati.istruzione.it/opendata/opendata/catalogo/elements1/", gsub("^/", "",
link))
      comando <- sprintf('curl -k -L -A "Mozilla/5.0" "%s" -o "%s"', url_completo,
percorso_salvataggio)

```

```

      system(comando)
      if (i <= length(date_modifica) && file.exists(percorso_salvataggio)) {
        data_estratta <- gsub(".*Modified:\\s*([0-9]{2}/[0-9]{2}/[0-9]{4}).*", "\\1",
date_modifica[i])
        try({
          df_temporaneo <- fread(percorso_salvataggio, colClasses = "character", encoding
= "UTF-8")
          df_temporaneo[, Ultima_Modifica_Portale := data_estratta]
          fwrite(df_temporaneo, percorso_salvataggio)
          cat("Data", data_estratta, "inserita con successo in", nome_file_nuovo, "\n")
        }, silent = TRUE)
      }
    }
    cat("\n")
  }, error = function(e) {
    cat("Errore URL:", url_area, "\n", e$message, "\n\n")
  })
})
print("fine")

```

2. DATA MANIPULATION/CLEANING ----

```

# Creazione Variabile Anno
file_list <- list.files(path = input_folder, pattern = "\\*.csv$", full.names = TRUE)
walk(file_list, function(file) {
  nome_file <- basename(file)
  df <- fread(file, colClasses = "character", encoding = "UTF-8")
  modificato <- FALSE
  anno_estratto <- stringr::str_extract(nome_file, "20[0-2][0-9]")
  anno_num <- suppressWarnings(as.numeric(anno_estratto))
  if (!is.na(anno_num) && anno_num >= 2000 && anno_num <= 2026) {
    df[, Anno := as.character(anno_num)]
    modificato <- TRUE
    message(paste("File da nome file:", nome_file, "->", anno_num))
  } else if ("ANNOSCOLASTICO" %in% names(df)) {
    anni_colonna <- stringr::str_extract(df$ANNOSCOLASTICO, "20[0-2][0-9]")
    if (!all(is.na(anni_colonna))) {
      df[, Anno := anni_colonna]
      modificato <- TRUE
      message(paste("Prendo Anno da ANNOSCOLASTICO:", nome_file))
    } else {
      message(paste("ANNOSCOLASTICO presente ma non leggibile:", nome_file))
    }
  } else if ("Anno" %in% names(df)) {
    message(paste("File già con Anno:", nome_file))
  } else {
    message(paste("File senza anno:", nome_file))
  }
  if (modificato) {
    fwrite(df, file)
    cat("  Anni trovati:", paste(unique(df$Anno), collapse = ", "), "\n")
  }
})

file_scaricati <- list.files(input_folder, pattern = "\\*.csv$", full.names = TRUE)
walk(file_scaricati, function(percorso_file) {
  nome_file <- basename(percorso_file)
  if (grepl("^Personale_", nome_file)) {
    nuovo_nome <- gsub("AS[0-9]{4}", "", nome_file)
    percorso_nuovo <- file.path(input_folder, nuovo_nome)
    if (percorso_file != percorso_nuovo) {
      file.rename(percorso_file, percorso_nuovo)
      cat("Pulito nome Personale:", nome_file, "->", nuovo_nome, "\n")
    }
  }
})

```

```

    }
  })

# Rinominare
file_scaricati <- list.files(input_folder, pattern = "\\*.csv$", full.names = TRUE)
cat("Trovati", length(file_scaricati), "file totali da elaborare.\n\n")
get_nome_pulito <- function(nome_file) {
  if (grepl("Scuole_", nome_file))      return(gsub("[0-9]{14}\\*.csv$", ".csv",
nome_file))
  if (grepl("Studenti_", nome_file))    return(gsub("[0-9]{14}\\*.csv$", ".csv",
nome_file))
  if (grepl("Bilancio", nome_file))     return(gsub("[0-9]{12}\\*.csv$", ".csv",
nome_file))
  if (grepl("Dati_di_", nome_file))     return(gsub("[0-9]{12}\\*.csv$", ".csv",
nome_file))
  if (grepl("Adozioni_", nome_file))    return(gsub("[0-9]{12}\\*.csv$", ".csv",
nome_file))
  if (grepl("Personale_", nome_file))   return(gsub("[0-9]+\\*.csv$", ".csv", nome_file))
  if (grepl("Sistema_", nome_file))    return(gsub("[0-9]+\\*.csv$", ".csv", nome_file))
  return(nome_file)
}

mappa_gruppi <- split(
  file_scaricati,
  sapply(basename(file_scaricati), get_nome_pulito)
)

file_effettivamente_accorpati <- c()
walk(names(mappa_gruppi), function(nome_pulito) {
  if (grepl("Edilizia", nome_pulito)) return(NULL)
  file_da_unire <- mappa_gruppi[[nome_pulito]]
  percorso_output <- file.path(input_folder, nome_pulito)
  if (length(file_da_unire) > 1) {
    cat("Unisco", length(file_da_unire), "file per:", nome_pulito, "\n")

    lista_df <- lapply(file_da_unire, function(f) {
      fread(f, colClasses = "character", encoding = "UTF-8")
    })
    db_unito <- rbindlist(lista_df, fill = TRUE)
    fwrite(db_unito, percorso_output)
    file_effettivamente_accorpati <- c(file_effettivamente_accorpati, file_da_unire)
  } else {
    if (file_da_unire[1] != percorso_output) {
      file.rename(file_da_unire[1], percorso_output)
    }
  }
})
if (length(file_effettivamente_accorpati) > 0) {
  file.remove(file_effettivamente_accorpati)
  cat("Rimossi", length(file_effettivamente_accorpati), "file originali.\n")
}

```

#Edilizia con doppio vincolo ----

```

tutti_i_file <- list.files(input_folder, pattern = "\\*.csv$", full.names = TRUE)
file_edilizia <- tutti_i_file[grepl("Edilizia", basename(tutti_i_file))]
if (length(file_edilizia) > 0) {
  nomi_puliti <- gsub("[0-9]+\\*.csv$", ".csv", basename(file_edilizia))
  lunghezze <- nchar(basename(file_edilizia))
  df_nomi <- data.frame(
    Percorso_Completo = file_edilizia,
    Originale         = basename(file_edilizia),
    Pulito             = nomi_puliti,
    Lunghezza          = lunghezze,
  )
}

```

```

stringsAsFactors = FALSE
)
gruppi_da_unire <- df_nomi %>%
  group_by(Pulito, Lunghezza) %>%
  summarise(Quanti = n(), .groups = "drop") %>%
  filter(Quanti > 1)
file_effettivamente_accorpati <- c()
if (nrow(gruppi_da_unire) > 0) {
  for (i in 1:nrow(gruppi_da_unire)) {
    nome_target <- gruppi_da_unire$Pulito[i]
    lunghezza_target <- gruppi_da_unire$Lunghezza[i]
    file_da_fondere <- df_nomi %>%
      filter(Pulito == nome_target, Lunghezza == lunghezza_target) %>%
      pull(Percorso_Completo)
    lista_df <- lapply(file_da_fondere, function(f) {
      fread(f, colClasses = "character", encoding = "UTF-8")
    })
    db_unito <- rbindlist(lista_df, fill = TRUE)
    percorso_salvataggio <- file.path(input_folder, nome_target)
    if (file.exists(percorso_salvataggio)) {
      nome_modificato <- gsub("\\.csv$", "_2.csv", nome_target)
      percorso_salvataggio <- file.path(input_folder, nome_modificato)
      cat("-> Nome già esistente! Salvo come:", nome_modificato, "\n")
    }
    fwrite(db_unito, percorso_salvataggio)
    file_effettivamente_accorpati <- c(file_effettivamente_accorpati, file_da_fondere)
  }
  if (length(file_effettivamente_accorpati) > 0) {
    file.remove(file_effettivamente_accorpati)
    cat("\nCancellati", length(file_effettivamente_accorpati), "file originali
Edilizia.\n")
  }
} else {
  cat("Nessun gruppo di file dell'Edilizia rispetta i criteri di accorpamento.\n")
}
file_rimasti <- list.files(input_folder, pattern = "\\..csv$", full.names = TRUE)
file_da_eliminare_extra <- file_rimasti[grepl("Edilizia_.*[0-9]{5,}",
basename(file_rimasti))]
if (length(file_da_eliminare_extra) > 0) {
  file.remove(file_da_eliminare_extra)
  cat("\nPulizia finale: eliminati", length(file_da_eliminare_extra), "file Edilizia con
più di 4 cifre.\n")
  print(basename(file_da_eliminare_extra))
} else {
  cat("\nNessun file Edilizia extra trovato.\n")
}

} else {
  cat("Non ci sono file che contengono 'Edilizia' nella cartella!\n")
}

# Data Catalog ----

if (!exists("cartella_output")) cartella_output <- input_folder
file_presenti <- list.files(input_folder, full.names = TRUE)
file_presenti <- file_presenti[tools::file_ext(file_presenti) != ""]

catalogo <- map_df(file_presenti, function(percorso_file) {
  nome_file <- basename(percorso_file)
  ext <- paste0(".", tolower(tools::file_ext(nome_file)))
  cat("Mappatura di:", nome_file, "...\\n")
  n_oss <- NA; n_var <- NA; variabili_interesse <- ""; intervallo_anni <- ""; data_agg <-
  ""; dati <- NULL

```

```

if (ext == ".csv") {
  dati <- tryCatch({
    fread(percorso_file, colClasses = "character", encoding = "UTF-8", fill = TRUE,
header = TRUE)
  }, error = function(e) {
    tryCatch({
      con <- file(percorso_file, "rb")
      linee_raw <- readLines(con, warn = FALSE)
      close(con)
      linee_pulite <- iconv(linee_raw, from = "latin1", to = "UTF-8", sub = " ")
      as.data.table(read.csv(text = linee_pulite, sep = ",", stringsAsFactors = FALSE,
check.names = FALSE, quote = ""))
    }, error = function(e2) NULL)
  })
  if (!is.null(dati) && nrow(dati) > 0) {
    colnames(dati) <- make.unique(iconv(colnames(dati), to = "UTF-8", sub = " "))
    dati <- dati %>% mutate(across(where(is.character), ~iconv(.x, to = "UTF-8", sub = "
"))))
  }
} else if (ext %in% c(".xlsx", ".xls")) {
  dati <- tryCatch({ as.data.frame(read_excel(percorso_file, sheet = 1, col_types =
"text")) }, error = function(e) NULL)
} else if (ext == ".xml") {
  tryCatch({
    xml_doc <- read_xml(percorso_file)
    nodi <- xml_children(xml_doc)
    if (length(nodi) == 1 && xml_name(nodi[1]) == "channel") nodi <-
xml_children(nodi[1])
    n_item <- nodi[xml_name(nodi) == "item"]
    target <- if(length(n_item) > 0) n_item else nodi
    if (length(target) > 0) {
      n_oss <- length(target)
      campi <- unique(tolower(xml_name(xml_children(target[1]))))
      n_var <- length(campi)
      variabili_interesse <- paste(campi, collapse = " | ")
    }
  }, error = function(e) NULL)
}
if (!is.null(dati) && nrow(dati) > 0) {
  n_oss <- nrow(dati)
  nomi_col <- colnames(dati)
  col_agg <- nomi_col[grepl("Ultima_Modifica_Portale$", nomi_col)]
  col_anno <- nomi_col[grepl("(?i)^anno$|(?i)^anno.*riferimento$", nomi_col)]
  if (length(col_agg) > 0) data_agg <- as.character(dati[[col_agg[1]]][1])
  if (length(col_anno) > 0) {
    v_anni <- na.omit(as.character(dati[[col_anno[1]]]))
    v_anni <- v_anni[v_anni != ""]
    if (length(v_anni) > 0) intervallo_anni <- paste0(min(v_anni), " - ", max(v_anni))
  }
  cols_clean <- nomi_col[!(nomi_col %in% c(col_agg, col_anno))]
  n_var <- length(cols_clean)
  variabili_interesse <- paste(tolower(cols_clean), collapse = " | ")
}
nota_file <- case_when(
  ext == ".xml" & !is.na(n_oss) ~ "File XML analizzato per nodi",
  is.null(dati) & !ext %in% c(".csv", ".xlsx", ".xls") ~ "Formato non analizzabile",
  !is.null(dati) & ext %in% c(".xlsx", ".xls") ~ "Excel letto con successo",
  TRUE ~ ""
)

data.frame(
  `nome dataset` = nome_file,
  `periodo/annualità disponibili` = intervallo_anni,

```

```

`ultimo aggiornamento disponibile` = data_agg,
`variabili di interesse` = variabili_interesse,
`n_osservazioni` = n_oss,
`n_variabili` = n_var,
`modalità di accesso` = "Download diretto (Scraping rvest/curl)",
`limiti tecnici (rate limit)` = "Nessuna API",
`formati scarico dati` = ext,
`note` = nota_file,
stringsAsFactors = FALSE, check.names = FALSE
)
})

file_catalogo <- file.path(data, "data_catalog_statistiche_istruzione.xlsx")
write_xlsx(catalogo, path = file_catalogo)
cat("Catalogo pronto:", file_catalogo, "\n")

```