

Web Scrapping - Italia Semplice

python 3.12+ library Selenium library Pandas License MIT

Automazione avanzata per l'estrazione sistematica degli interventi di semplificazione amministrativa dal portale nazionale.

Descrizione

Questa pipeline è stata sviluppata per l'estrazione di dati (procedure e relativi interventi di semplificazione) dal portale istituzionale [Italia Semplice](#).

Viene gestita la navigazione dinamica tra le procedure, il caricamento asincrono dei contenuti ed estratti i dettagli degli interventi organizzandoli in un formato strutturato (CSV/Excel) pronto per l'analisi statistica o l'integrazione in database.

Architettura e Struttura

```
scraping_italiasemplice/  
├─ main.py           # Coordina il flusso e il salvataggio dati  
├─ config.py         # Configurazioni generali  
├─ scraper_engine.py # Gestione del driver Selenium (Logica Anti-bot)  
├─ parser_utils.py   # Logica di estrazione (Regex e selettori XPATH)  
├─ requirements.txt  # Elenco delle dipendenze Python  
├─ output/  
│   └─ data/         # Risultati finali (webscraping_final.csv)  
│   └─ logs/         # Log di esecuzione (scraping_log.log)
```

Requisiti e Installazione

- Python 3.12+
- Google Chrome installato
- Installazione dipendenze: Apri il terminale nella cartella del progetto e digita:

```
pip install -r requirements.txt
```

Utilizzo

1. Configurazione

È possibile definire l'intervallo di ID da analizzare modificando il file config.py:

```
ID_START = 0  
ID_END = 700
```

2. Esecuzione

Avvia lo script principale:

```
python3 main.py
```

3. Monitoraggio

Il sistema fornisce feedback in tempo reale tramite:

- Terminale: Avanzamento e ID correntemente elaborati.
- Log file: Dettagli tecnici e segnalazione di eventuali pagine vuote in output/logs/scraping_log.log.

Scelte Progettuali e Problem Solving

Per rendere la pipeline professionale e robusta, sono state implementate le seguenti soluzioni:

- **Stabilità:** Il salvataggio è incrementale. Se lo script si ferma, i dati scaricati fino a quel momento sono già salvati nel CSV.
- **Gestione Anti-Bot:** Utilizzo di undetected-chromedriver per simulare un comportamento umano e minimizzare i rischi di blocco da parte del server.
- **Memory Management:** Il browser viene riavviato automaticamente ogni 20 procedure per liberare la RAM.
- **Parsing Adattivo:** Utilizzo combinato di XPATH e Regex per gestire variazioni nel layout HTML tra le diverse schede.

Dati Estratti

Il file finale webscraping_final.csv contiene:

- Dati Procedura: ID, Nome Procedura, Settore, Categoria, Beneficiario, Tipo PA Responsabile.
- Dati Intervento: Intervento, Anno, Descrizione Intervento, Tipo Intervento, Natura Intervento e Riferimenti.
- Metadata: URL diretto per la verifica manuale del dato.

